



Natural Language Processing: Pretrain, Finetune

HSE Faculty of Computer Science

Murat Khazhgeriev



Table of Content

- Recap
- Pretraining, Posttraining
- Parameter-Efficient Finetuning (PEFT)
- Benchmarking



Table of Content

- **Recap**
- Pretraining, Posttraining
- Parameter-Efficient Finetuning (PEFT)
- Benchmarking



Let's take a look at a translation task



Кот в квартире



Break down an input into tokens

↑
Кот, в, квартире

↑
Кот в квартире



Match a token to a corresponding embedding

$(1,0,0), (0,1,0), (0,0,1)$



Кот, в, квартире



Кот в квартире



Match a token to a corresponding embedding

$(1,0,0)$, $(0,1,0)$, $(0,0,1)$



Кот, в, квартире



Кот в квартире



Match a token to a corresponding embedding

$(1,0,0)$, $(0,1,0)$, $(0,0,1)$

↑
Кот, в, квартире

↑
Кот в квартире




Match a token to a corresponding embedding

$(1,0,0)$, $(0,1,0)$, $(0,0,1)$


↑
Кот, в, квартире

↑
Кот в квартире


Encode input data into a semantically rich vector/matrices




Forward encoded data along with a special <bos> token to a decoder




The decoder outputs a probability distribution over all known tokens (i.e. vocabulary)




Pick the next token




Said token is used as an input to the decoder




Continue until $\langle \text{eos} \rangle$ is generated



While tuning the model measure how far is the output distribution to what was expected




We can also leverage Encoder and Decoder separately







Encoder is good at, well, encoding input data into embeddings



Many hyped generative models are Decoders



Many hyped generative models are Decoders





“Prompt” is an input that we pass to a language model

Что такое промпт?

 **Промпт** (от англ. *prompt*) — это текстовая инструкция или запрос, который пользователь вводит в ИИ-систему (например, ChatGPT, Midjourney, Stable Diffusion), чтобы получить нужный ответ или результат.


Виды промптов:

- Текстовые** (для ChatGPT, Claude, Gemini) – например:
 - "Напиши краткое содержание романа 'Преступление и наказание'"
 - "Придумай бизнес-план для кофейни"
- Генерация изображений** (для Midjourney, DALL-E) – например:
 - "Реалистичный кот в космосе, 4K, детализированный"
- Программирование** (для GitHub Copilot, ChatGPT) – например:
 - "Напиши код Python для парсинга сайта"

Как писать эффективные промпты?

- **Будьте конкретны** – чем точнее запрос, тем лучше результат.
- **Добавляйте контекст** – укажите стиль, тон, длину ответа.
- **Экспериментируйте** – меняйте формулировки, если ИИ не понимает.

“Prompt” is an input that we pass to a language model



The screenshot shows a dark-themed chat interface. At the top right, there is a text input field containing the text "Что такое промпт?". Below this, on the left, is a small blue circular icon with a white bird-like symbol. To its right is a paragraph of text defining a prompt. Below the definition, there is a section titled "Виды промптов:" followed by a numbered list of three types of prompts with their respective examples. At the bottom, there is a section titled "Как писать эффективные промпты?" followed by a bulleted list of three tips.

Что такое промпт?

Промпт (от англ. *prompt*) — это текстовая инструкция или запрос, который пользователь вводит в ИИ-систему (например, ChatGPT, Midjourney, Stable Diffusion), чтобы получить нужный ответ или результат.

Виды промптов:

1. **Текстовые** (для ChatGPT, Claude, Gemini) – например:
 - "Напиши краткое содержание романа 'Преступление и наказание'"
 - "Придумай бизнес-план для кофейни"
2. **Генерация изображений** (для Midjourney, DALL-E) – например:
 - "Реалистичный кот в космосе, 4K, детализированный"
3. **Программирование** (для GitHub Copilot, ChatGPT) – например:
 - "Напиши код Python для парсинга сайта"

Как писать эффективные промпты?

- **Будьте конкретны** – чем точнее запрос, тем лучше результат.
- **Добавляйте контекст** – укажите стиль, тон, длину ответа.
- **Экспериментируйте** – меняйте формулировки, если ИИ не понимает.

Вот это - промпт




Many hyped generative models are Decoders



Пользовательский промпт: Какая погода нас ждет завтра?



Many hyped generative models are Decoders



Большинство находящихся на слуху приложений в своей основе - декодеры






Table of Content

- Recap
- **Pretraining, Posttraining**
- Parameter-Efficient Finetuning (PEFT)
- Benchmarking



Use unlabeled text to automatically process large text corpora

Счито и маш

Граф расхохотался. Другие гости, видя, что Шиншин ведет разговор, подошли послушать. Берг, не замечая ни насмешки, ни равнодушия, продолжал рассказывать о том, как переводом в гвардию он уже выиграл чин перед своими товарищами по корпусу, как в военное время ротного командира могут убить и он, оставшись старшим в роте, может очень легко быть ротным, и как в полку все любят его, и как его папенька им доволен. Берг, видимо, наслаждался, рассказывая все это, и, казалось, не подозревал того, что у других людей могли быть тоже свои интересы. Но все, что он рассказывал, было так мило, степенно, наивность молодого эгоизма его была так очевидна, что он обезоруживал своих слушателей. — Ну, батюшка, вы и в пехоте и в кавалерии, везде пойдете в ход; это я вам предрекаю, — сказал Шиншин, трепля его по плечу и спуская ноги с оттоманки. Берг радостно улыбнулся. Граф, а за ним и гости вышли в гостиную.



Use unlabeled text to automatically process large text corpora

Граф расхохотался. Другие гости, видя, что Шиншин ведет разговор, подошли послушать. Берг, не замечая ни насмешки, ни равнодушия, продолжал рассказывать о том, как переводом в гвардию он уже выиграл чин перед своими товарищами по корпусу, как в военное время ротного командира могут убить и он, оставшись старшим в роте, может очень легко быть ротным, и как в полку все любят его, и как его папенька им доволен. Берг, видимо, наслаждался, рассказывая все это, и, казалось, не подозревал того, что у других людей могли быть тоже свои интересы. Но все, что он рассказывал, было так мило, степенно, наивность молодого эгоизма его была так очевидна, что он обезоруживал своих слушателей. — Ну, батюшка, вы и в пехоте и в кавалерии, везде пойдете в ход; это я вам предрекаю, — сказал Шиншин, трепля его по плечу и спуская ноги с оттоманки. Берг радостно улыбнулся. Граф, а за ним и гости вышли в гостиную.




Use unlabeled text to automatically process large text corpora

pretrain

~ 18 млн.

Граф расхохотался. Другие гости, видя, что Шиншин ведет разговор, подошли послушать. Берг, не замечая ни насмешки, ни равнодушия, продолжал рассказывать о том, как переводом в гвардию он уже выиграл чин перед своими товарищами по корпусу, как в военное время ротного командира могут убить и он, оставшись старшим в роте, может очень легко быть ротным, и как в полку все любят его, и как его папенька им доволен. Берг, видимо, наслаждался, рассказывая все это, и, казалось, не подозревал того, что у других людей могли быть тоже свои интересы. Но все, что он рассказывал, было так мило, степенно, наивность молодого эгоизма его была так очевидна, что он обезоруживал своих слушателей. — Ну, батюшка, вы и в пехоте и в кавалерии, везде пойдете в ход; это я вам предрекаю, — сказал Шиншин, трепля его по плечу и спуская ноги с оттоманки. Берг радостно улыбнулся. Граф, а за ним и гости вышли в гостиную.

Next, we need to align model's behaviour with users' expectations




Supervised finetuning matches potential prompts with expected results

Supervised Finetuning (SFT)


Step 1

Collect demonstration data, and train a supervised policy.


A prompt is sampled from our prompt dataset.



A labeler demonstrates the desired output behavior.




This data is used to fine-tune GPT-3 with supervised learning.



Step 2

Collect comparison data, and train a reward model.


A prompt and several model outputs are sampled.



A labeler ranks the outputs from best to worst.



This data is used to train our reward model.



Step 3

Optimize a policy against the reward model using reinforcement learning.

A new prompt is sampled from the dataset.



The policy generates an output.




Once upon a time...

The reward model calculates a reward for the output.



The reward is used to update the policy using PPO.






Prompt example	Expected results
Какие симптомы у гриппа?	Основные симптомы гриппа: высокая температура (38°C+), озноб, головная боль, боль в мышцах, слабость, кашель, боль в горле.
Как отличить COVID-19 от ОРВИ?	COVID-19 чаще вызывает потерю вкуса/обоняния, одышку и длительную слабость, тогда как ОРВИ обычно протекает легче с насморком и чиханием.
Какая доза парацетамола для взрослых?	Максимальная разовая доза — 1000 мг, суточная — не более 4000 мг. Принимать с интервалом 4–6 часов.
Что делать при гипертоническом кризе?	Измерить давление, вызвать скорую. До приезда врача — лечь, принять прописанный препарат (например, каптоприл 25 мг под язык).
Какие анализы сдать при анемии?	Общий анализ крови (гемоглобин, эритроциты), ферритин, сывороточное железо, витамин B12, фолиевая кислота.

Next, we train the model not only to mimic the expected behavior, but to seek reinforcement from humans

RLHF



What model tells you and what it thinks could be two separate things






Table of Content

- Recap
- Pretraining, Posttraining
- **Parameter-Efficient Finetuning (PEFT)**
- Benchmarking

Table of Content

- Recap
- Pretraining, Posttraining
- Parameter-Efficient Finetuning (PEFT)
 - **Manual prompting**
 - Soft prompting (prompt tuning)
 - Adapters
- Benchmarking

PEFT

}

настройка модели
под себя

Chain of Thoughts

prompt { example {

Standard Prompting

Model Input

Q: Roger has 5 tennis balls. He buys 2 more cans of tennis balls. Each can has 3 tennis balls. How many tennis balls does he have now?

A: The answer is 11.

Q: The cafeteria had 23 apples. If they used 20 to make lunch and bought 6 more, how many apples do they have?

Model Output

A: The answer is 27. ❌

Chain-of-Thought Prompting

Model Input

Q: Roger has 5 tennis balls. He buys 2 more cans of tennis balls. Each can has 3 tennis balls. How many tennis balls does he have now?

A: Roger started with 5 balls. 2 cans of 3 tennis balls each is 6 tennis balls. $5 + 6 = 11$. The answer is 11.




Q: The cafeteria had 23 apples. If they used 20 to make lunch and bought 6 more, how many apples do they have?

Model Output

A: The cafeteria had 23 apples originally. They used 20 to make lunch. So they had $23 - 20 = 3$. They bought 6 more apples, so they have $3 + 6 = 9$. The answer is 9. ✅

When asked to “think”, the model gives the right answer

Impersonalisation



Chain of Thoughts

Standard Prompting

Model Input

Q: Roger has 5 tennis balls. He buys 2 more cans of tennis balls. Each can has 3 tennis balls. How many tennis balls does he have now?

A: The answer is 11.

Q: The cafeteria had 23 apples. If they used 20 to make lunch and bought 6 more, how many apples do they have?

Model Output

A: The answer is 27. ❌

Chain-of-Thought Prompting

Model Input

Q: Roger has 5 tennis balls. He buys 2 more cans of tennis balls. Each can has 3 tennis balls. How many tennis balls does he have now?

A: Roger started with 5 balls. 2 cans of 3 tennis balls each is 6 tennis balls. $5 + 6 = 11$. The answer is 11.

Q: The cafeteria had 23 apples. If they used 20 to make lunch and bought 6 more, how many apples do they have?

Model Output

A: The cafeteria had 23 apples originally. They used 20 to make lunch. So they had $23 - 20 = 3$. They bought 6 more apples, so they have $3 + 6 = 9$. The answer is 9. ✅

When asked to “think”, the model gives the right answer

Self-Consistency





Figure 1: The self-consistency method contains three steps: (1) prompt a language model using chain-of-thought (CoT) prompting; (2) replace the “greedy decode” in CoT prompting by sampling from the language model’s decoder to generate a diverse set of reasoning paths; and (3) marginalize out the reasoning paths and aggregate by choosing the most consistent answer in the final answer set.

Prompt Format Matters


Prompt	Label Names
Review: This movie is amazing! Answer: Positive	Positive, Negative • •
Review: Horrific movie, don't see it. Answer:	
Review: This movie is amazing! Answer: good	good, bad • •
Review: Horrific movie, don't see it. Answer:	
My review for last night's film: This movie is amazing! The critics agreed that this movie was good	good, bad
My review for last night's film: Horrific movie, don't see it. The critics agreed that this movie was	
Here is what our critics think for this month's films.	positive, negative
One of our critics wrote "This movie is amazing!". Her sentiment towards the film was positive.	
One of our critics wrote "Horrific movie, don't see it". Her sentiment towards the film was	
Critical reception [edit]	good, bad
In a contemporary review, Roger Ebert wrote "This movie is amazing!". Entertainment Weekly agreed, and the overall critical reception of the film was good.	
In a contemporary review, Roger Ebert wrote "Horrific movie, don't see it". Entertainment Weekly agreed, and the overall critical reception of the film was	
Review: This movie is amazing! Positive Review? Yes	Yes, No
Review: Horrific movie, don't see it. Positive Review?	



Example order is suspiciously too important

Depending on the example order in the prompt, we can get

- Near state-of-the-art accuracy
- Near random accuracy



True Labels **Do Not** Matter






Table of Content

- Recap
- Pretraining, Posttraining
- Parameter-Efficient Finetuning (PEFT)
 - Manual prompting
 - **Soft prompting (prompt tuning)**
 - Adapters
- Benchmarking

Let's train our prompts in a Parameter Efficient Way







Table of Content

- Recap
- Pretraining, Posttraining
- Parameter-Efficient Finetuning (PEFT)
 - Manual prompting
 - Soft prompting (prompt tuning)
 - **Adapters**
- Benchmarking

Adapters are injected along with frozen model parameters



You can even combine them together

	Models	Strategies	Ckpt.	Emb.	Adpt. Red.	(p.) de	en→de	de→de	(p.) ko	en→ko	ko→ko
(1)	mBERT _{BASE}	-	-	-	-	-	70.0	75.5	-	69.7	72.9
(2)	XLNet _{LARGE}	-	-	-	-	-	82.5	85.4	-	80.4	86.4
(3)	XGLM _{1.7B}	-	-	-	-	45.4	-	-	45.17	-	-
(4)	BigScience	-	-	-	-	34.1	44.8	67.4	-	-	-
(5)	BigScience	Emb	118,500	wte,wpe	-	41.4	50.7	74.3	34.4	45.6	53.4
(6)	BigScience	Emb→Adpt	118,500	wte,wpe	16	40.0	50.5	69.9	33.8	40.4	51.8
(7)	BigScience	Emb+Adpt	118,500	wte	16	42.4	58.4	73.3	38.8	49.7	55.7
(8)	BigScience	Emb+Adpt	118,500	wte	48	42.4	57.6	73.7	36.3	48.3	52.9
(9)	BigScience	Emb+Adpt	118,500	wte	384	42.4	55.3	74.2	37.5	49.4	54.6
(10)	BigScience	Emb+Adpt	100,500	wte	16	44.3	56.9	73.2	37.5	48.6	50.8
(11)	BigScience	Emb+Adpt	12,000	wte	16	33.5	55.2	70.5	32.9	46.4	53.3
(12)	BigScience	Emb+Adpt	100,500	wte,wpe	16	-	-	-	37.5	53.5	63.5
(13)	BigScience	Emb+Adpt	118,500	wte,wpe	16	44.7	64.9	73.0	-	-	-

Table 3: Evaluation of language adaptation for German (de) and Korean (ko) on NLI with three baselines (mBERT_{BASE} (Devlin et al., 2019), XLNet_{BASE} (Conneau et al., 2020a), XGLM_{1.3B} (Lin et al., 2021)). "Strategies" column indicates language adaptation strategies, which cover Embedding-only (Emb), Embedding-then-Adapters (Emb→Adpt) and Embedding-and-Adapters (Emb+Adpt). "Ckpt." column stands for the BigScience pretrained checkpoint, "Emb." column the types of embedding layers (wte: token embedding, wpe: positional embedding), and "Adpt. Red." column the reduction factor for language adapters. "(p.) de/ko" column reports the prompt-based zero-shot evaluation result, "en→de/ko" cross-lingual result, and "de/ko→de/ko" supervised finetuning result. Row (7) is bolded as all other language adaptation strategies and design choices are compared against it.

Low Rank Adapters, everybody




Figure 1: Our reparametrization. We only train A and B .

IA3




Figure 1: Diagram of $(IA)^3$ and the loss terms used in the T-Few recipe. *Left:* $(IA)^3$ introduces the learned vectors l_k , l_v , and l_{ff} which respectively rescale (via element-wise multiplication, visualized as $\odot$) the keys and values in attention mechanisms and the inner activations in position-wise feed-forward networks. *Right:* In addition to a standard cross-entropy loss L_{LM} , we introduce an unlikelihood loss L_{UL} that lowers the probability of incorrect outputs and a length-normalized loss L_{LN} that applies a standard softmax cross-entropy loss to length-normalized log-probabilities of all output choices.

IA3




Figure 2: Accuracy of PEFT methods with L_{UL} and L_{LN} when applied to T0-3B. Methods that with variable parameter budgets are represented with larger and smaller markers for more or less parameters.




Figure 3: Accuracy of different few-shot learning methods. T-Few uses (IA)³ for PEFT methods of T0, T0 uses zero-shot learning, and T5+LM and the GPT-3 variants use few-shot ICL. The x-axis corresponds to inference costs; details are provided in section 4.2.

When to use each (a rule of thumb!)

- 10s-100s of examples = prompt engineering, IA3
- 100s, 1000s of examples = prompt tuning, IA3
- more examples = LoRA adapters



Table of Content

- Recap
- Pretraining, Posttraining
- Parameter-Efficient Finetuning (PEFT)
- **Benchmarking**

Model-Free: Perplexity

$$PPL_{model} = \exp \left(- \sum_{i=1}^t \log(P_{\theta}(x_i | x_j \neq x_i)) \right)$$

I am Groot


Predicted: [[0.45 0.1 0.45], [0.05 0.9 0.05], [0.05 0.05 0.9]]

Target: [[1 0 0], [0 1 0], [0 0 1]]


Perplexity

$$PPL = \exp \left(\frac{-1 * \log(0.45) + -1 * \log(0.9) + -1 * \log(0.9)}{3} \right) = 1.4$$


A holistic view on LLM benchmarking



Reference-Based Evaluation



BERTScore



BLEU

Reference: The sun is shinning.

Candidate: The sun is in the sky.

$$\text{BLEU-1} = \frac{\sum \square}{\sum \square} = \frac{3}{6} = 0.5$$

	the	is	sun	in	shinning	sky
min(count candidate, count reference)	1	1	1	0	0	0
Count candidate	2	1	1	1	0	1

BLEU

Reference: The sun is shining.

Candidate: The sun is in the sky.

$$\text{BLEU-1} = \frac{\sum \square}{\sum \square} = \frac{3}{6} = 0.5$$

	the	is	sun	in	shinning	sky
min(count candidate, count reference)	1	1	1	0	0	0
Count candidate	2	1	1	1	0	1

