


Agents

Содержание


- Так что же ты такое, агент?
- Как строить процессы вокруг агентов / агентов вокруг процессов?
- Оцениваем работу моделей: как полюбить черный ящик и начать жить
- A2A
- Вместо заключения




Что такое LLM?



Encoder генерирует качественное семантическое представление входа



Encoder генерирует качественное семантическое представление входа




LLM генерирует токен за токеном итеративно




Пользовательский промт: Какая погода нас ждет завтра?


LLM генерирует токен за токеном итеративно



LLM генерирует токен за токеном итеративно



LLM генерирует токен за токеном итеративно



Так что же ты такой, агент?

Определение

Определение агента

Определение агента

Агент – нечто, что взаимодействует с некоторой **средой**, пользуясь действиями из доступного **инструментария**

Определение агента



Агент – нечто, что взаимодействует с некоторой **средой**, пользуясь действиями из доступного **инструментария**

Агент – система, которая **независимо** выполняет вашу работу

Определение агента

Агент – нечто, что взаимодействует с некоторой **средой**, пользуясь действиями из доступного **инструментария**


Агент – система, которая **независимо** выполняет вашу работу



на базе LLM.

Агент – система, независимо от человека выполняющая работу, **итеративно** взаимодействуя с некоторой средой при помощи доступного инструментария

Агент, пользуясь инструментами, размышляя о выполнении задачи, может выполнять ее автономно



Можно выделить три широких типа инструментов, доступных агенту

Дополнение информации агента

- Выход в интернет
- Парсинг нетекстовых типов данных
(звука, изображений)
- Доступ к почте (чтение)
- Хожение по API
- Retrieval Augmented Generation
(RAG)*
- etc.

Можно выделить три широких типа инструментов, доступных агенту

Дополнение информации агента

- Выход в интернет
- Парсинг нетекстовых типов данных (звука, изображений)
- Доступ к почте (чтение)
- Хожение по API
- Retrieval Augmented Generation (RAG)*
- etc.

Расширение возможностей агента

- Переводчики (в широком смысле)
e.g. языков, единиц измерения
- Доступ к геолокации, времени
- Интерпретаторы и компиляторы
языков программирования
- Калькулятор
- etc.

Можно выделить три широких типа инструментов, доступных агенту

Дополнение информации агента

- Выход в интернет
- Парсинг нетекстовых типов данных (звука, изображений)
- Доступ к почте (чтение)
- Хожение по API
- Retrieval Augmented Generation (RAG)*
- etc.

Расширение возможностей агента

- Переводчики (в широком смысле) e.g. языков, единиц измерения
- Доступ к геолокации, времени
- Интерпретаторы и компиляторы языков программирования
- Калькулятор
- etc.


Возможность агента действовать

- Управление роботами (в т.ч. автомобилями)
- Исполнение написанного агентом кода и запросов
- Доступ к почте (с возможностью писать)
- etc.

Retrieval-Augmented Generation (RAG) тоже может быть одним из инструментов

Ванильная модель


Вопрос клиента: «Каковы условия досрочного погашения потребительского кредита?»



Retrieval-Augmented Generation (RAG) тоже может быть одним из инструментов

Ванильная модель

Вопрос клиента: «Каковы условия досрочного погашения потребительского кредита?»





Ответ модели: «Обычно досрочное погашение кредита возможно, но может сопровождаться комиссией или ограничениями. Уточните детали в вашем банке.»

Retrieval-Augmented Generation (RAG) тоже может быть одним из инструментов

Ванильная модель


Вопрос клиента: «Каковы условия досрочного погашения потребительского кредита?»

Контекст: *найденные релевантные факты из базы данных*



Данные из векторной базы (найжены в PDF с тарифами банка):
«Досрочное погашение возможно после 6 месяцев выплат. Комиссия – 1% от суммы погашения. Требуется письменное уведомление за 3 рабочих дня.»

Retrieval-Augmented Generation (RAG) тоже может быть одним из инструментов



Так что же ты такой, агент?

Think, Act, Observe

Reason + Act = ReAct

User: Какой сейчас день недели в Токио?

Reason + Act = ReAct

User: Какой сейчас день недели в Токио?

Agent:

• *Thought:* Чтобы узнать день недели, нужно сначала получить текущее время в Токио.

Action: Вызвать инструмент `GetTime(city="Токио")`

Reason + Act = ReAct

The diagram illustrates the ReAct process flow with red annotations. A large red curly brace on the left groups the Agent's internal steps. A red arrow points from the User's question to the Agent's response. Inside the Agent's response, a red arrow points from the Thought to the Action, and another red arrow points from the Action to the Observation. The Action and Observation lines are underlined in red.

→ **User:** Какой сейчас день недели в Токио?

Agent:

Thought: Чтобы узнать день недели, нужно сначала получить текущее время в Токио.

Action: Вызвать инструмент `GetTime(city="Токио")`

Observation: Инструмент вернул: "27 апреля 2025 года, воскресенье"

Reason + Act = ReAct

User: Какой сейчас день недели в Токио?

Agent:

Thought: Чтобы узнать день недели, нужно сначала получить текущее время в Токио.

Action: Вызвать инструмент `GetTime(city="Токио")`

Observation: Инструмент вернул: "27 апреля 2025 года, воскресенье"

Thought: Инструмент сообщил, что сегодня воскресенье. Теперь мне хватает информации для ответа.

Action: Используй `ReturnAnswer()`

Reason + Act = ReAct

User: Какой сейчас день недели в Токио?

Agent:

Thought: Чтобы узнать день недели, нужно сначала получить текущее время в Токио.

Action: Вызвать инструмент `GetTime(city="Токио")`

Observation: Инструмент вернул: "27 апреля 2025 года, воскресенье"

Thought: Инструмент сообщил, что сегодня воскресенье. Теперь мне хватает информации для ответа.

Action: Используй `ReturnAnswer()`

Answer: Сегодня в Токио воскресенье.

Пример системного промпта ReAct

Role → Ты - интеллектуальный агент, твоя задача - решать пользовательские запросы пошагово, чередуя размышления (Thought) и действия (Action), используя доступные инструменты.

Instrument { Тебе доступны следующие инструменты:

- Search(query): поиск информации в интернете по запросу.
- Calculator(expression): выполнение математических вычислений.
- FileReader(file_reference): чтение и извлечение данных из документов.
- TableAnalyzer(table_reference, query): анализ таблиц и структурированных данных.

ReAct { Процесс работы (повторять при необходимости):

- 1.Thought: размышления о задаче.
- 2.Action: вызов инструмента.
- 3.Observation: результат действия.

Answer: финальный ответ, полученный путем размышления.

Пример:

User:

Exam Назови столицу Франции и сколько человек там живёт?

Agent:

Thought: Столицу Франции я знаю — Париж. Нужно уточнить население.

Action: Search("Population of Paris 2024")

Observation: Население около 2,1 млн человек.

Answer: Столица Франции — Париж. Население — около 2,1 млн.




Архитектура агента на основе генеративной модели



Содержание

- Так что же ты такое, агент?
- **Как строить процессы вокруг агентов / агентов вокруг процессов?**
- Оцениваем работу моделей: как полюбить черный ящик и начать жить
- A2A
- Вместо заключения



В каких процессах агенты могут быть полезны

В каких процессах агенты могут быть полезны

01. Сложные процессы принятия решений:

Рабочие процессы, требующие тонких суждений, обработки исключений или решений, зависящих от контекста.

Пример: Принятие решений о выдаче кредитов, наложение/снятие санкций в рамках проверки мошеннических действий

В каких процессах агенты могут быть полезны

01. Сложные процессы принятия решений:

Рабочие процессы, требующие тонких суждений, обработки исключений или решений, зависящих от контекста.

Пример: Принятие решений о выдаче кредитов, наложение/снятие санкций в рамках проверки мошеннических действий

02. Трудноподдерживаемые правила:

Системы с громоздкими и сложными наборами правил, где внесение изменений становится дорогостоящим или приводит к ошибкам.

Пример: Актуализация нормативных требований, проверка поставщиков в условиях изменяющихся требований

В каких процессах агенты могут быть полезны

01. Сложные процессы принятия решений:

Рабочие процессы, требующие тонких суждений, обработки исключений или решений, зависящих от контекста.

Пример: Принятие решений о выдаче кредитов, наложение/снятие санкций в рамках проверки мошеннических действий

02. Трудноподдерживаемые правила:

Системы с громоздкими и сложными наборами правил, где внесение изменений становится дорогостоящим или приводит к ошибкам.

Пример: Актуализация нормативных требований, проверка поставщиков в условиях изменяющихся требований

03. Работа с неструктурированными данными:

Сценарии, где требуется интерпретация естественного языка, извлечение смысла из документов или общение с пользователями

Пример: Автоматизированная проверка обращений клиентов, внутрикорпоративный помощник с доступом к почте

Агенту стоит дать инструкции, но ожидать от него можно поведения реального сотрудника

Инструкции агента могут не содержать четких правил, а просто принципы из должностной инструкции и нашего представления о хорошей работе:

«Если заказ отправлен, а пользователь спрашивает об изменении адреса:

Извиниться,

Объяснить, что изменить адрес нельзя,

Предложить альтернативы — отмену, повторный заказ или помощь с курьером.»

Агенту стоит дать инструкции, но ожидать от него можно поведения реального сотрудника

Инструкции агента могут не содержать четких правил, а просто принципы из должностной инструкции и нашего представления о хорошей работе:

«Если заказ отправлен, а пользователь спрашивает об изменении адреса:
Извиниться,
Объяснить, что изменить адрес нельзя,
Предложить альтернативы — отмену, повторный заказ или помощь с курьером.»

User: «Я хочу обновить адрес доставки, но мой заказ уже отправлен.»

Агенту стоит дать инструкции, но ожидать от него можно поведения реального сотрудника

Инструкции агента могут не содержать четких правил, а просто принципы из должностной инструкции и нашего представления о хорошей работе:

«Если заказ отправлен, а пользователь спрашивает об изменении адреса:
Извиниться,
Объяснить, что изменить адрес нельзя,
Предложить альтернативы — отмену, повторный заказ или помощь с курьером.»

User: «Я хочу обновить адрес доставки, но мой заказ уже отправлен.»

Agent: «Так как посылка уже отправлена, я не могу изменить адрес напрямую. Однако вы можете попробовать запросить перенаправление через UPS. Хотите, я помогу найти для вас трекинг-номер и контакты UPS?»

Агенту стоит дать инструкции, но ожидать от него можно поведения реального сотрудника

Инструкции агента могут не содержать четких правил, а просто принципы из должностной инструкции и нашего представления о хорошей работе:

«Если заказ отправлен, а пользователь спрашивает об изменении адреса:
Извиниться,
Объяснить, что изменить адрес нельзя,
Предложить альтернативы — отмену, повторный заказ или помощь с курьером.»

User: «Я хочу обновить адрес доставки, но мой заказ уже отправлен.»

Agent: «Так как посылка уже отправлена, я не могу изменить адрес напрямую. Однако вы можете попробовать запросить перенаправление через UPS. Хотите, я помогу найти для вас трекинг-номер и контакты UPS?»

Хорошие практики работы с агентом

- Использовать существующие документы и описания процессов

Плохо: «Помоги мне с обработкой входящих заявок.» (Агент не имеет контекста или инструкций)

Неплохо: «Вот должностная инструкция для специалиста по обработке заявок. Пожалуйста, используй ее для классификации и распределения новых запросов, поступающих на почту support@company.com.»

(Агент получает четкие инструкции на основе существующего документа)

Хорошие практики работы с агентом

- Использовать существующие документы и описания процессов
- По возможности разбивать задачу на более гранулярные составляющие

Плохо: «Напиши отчет о продажах за последний квартал.» (Слишком общая задача, требующая множество шагов)

Неплохо: «Сначала получи данные о продажах из CRM за последний квартал. Затем, агрегируй данные по продуктам и регионам. После этого, создай сводную таблицу в Google Sheets. И наконец, напиши краткий обзор ключевых тенденций, основываясь на этой таблице.» (Задача разбита на последовательные, четкие шаги)

Хорошие практики работы с агентом

- Использовать существующие документы и описания процессов
- По возможности разбивать задачу на более гранулярные составляющие
- Чем четче вы опишите каждое действие, тем проще агенту будет следовать вашим ожиданиям
- **Плохо:** «Ответь на вопросы клиента.» (Непонятно, как именно ответить и что учесть)
- **Неплохо:** «Ответь на вопрос клиента 'Когда будет доставлен мой заказ?', используя информацию из системы отслеживания заказов. Если статус 'в пути', сообщи ориентировочную дату доставки. Если 'доставлен', укажи дату и время доставки. Если 'задержка', извинись и предложи связаться с менеджером.» (Каждое действие четко описано с условиями)

Хорошие практики работы с агентом


- Использовать существующие документы и описания процессов
- По возможности разбивать задачу на более гранулярные составляющие
- Чем четче вы опишите каждое действие, тем проще агенту будет следовать вашим ожиданиям
- По возможности продумайте, что будет, если агент получит неожиданные/неполные данные от пользователя

Плохо: «Запиши клиента на прием.» (Не предусмотрено, что делать, если клиент не указал имя или предпочитаемое время)


Неплохо: «Запиши клиента на прием. Если клиент не предоставил имя, попроси его указать. Если предпочитаемое время уже занято, предложи ближайшие свободные слоты. Если тип услуги неясен, уточни у клиента, прежде чем записывать.»

(Предусмотрены сценарии обработки неполных или неоднозначных данных)


Агент – больше, чем просто LLM




Инструментом агента может быть обращение к другому агенту




Инструментом агента может быть обращение к другому агенту



Model Context Protocol (MCP)




Model Context Protocol (MCP)




Содержание

- Так что же ты такое, агент?
- Как строить процессы вокруг агентов / агентов вокруг процессов?
- **Оцениваем работу моделей: как полюбить черный ящик и начать жить**
- A2A
- Вместо заключения

Агента можно оценивать как LLM, а можно как сервис в совокупности.
И это важно.



Пример анализа LLM как самостоятельной модели



Пример анализа LLM как самостоятельной модели

Conceptual Physics	When you drop a ball from rest it accelerates downward at 9.8 m/s^2 . If you instead throw it downward assuming no air resistance its acceleration immediately after leaving your hand is	
	(A) 9.8 m/s^2	✓
	(B) more than 9.8 m/s^2	✗
	(C) less than 9.8 m/s^2	✗
	(D) Cannot say unless the speed of throw is given.	✗
College Mathematics	In the complex z -plane, the set of points satisfying the equation $z^2 = z ^2$ is a	
	(A) pair of points	✗
	(B) circle	✗
	(C) half-line	✗
	(D) line	✓

Figure 4: Examples from the Conceptual Physics and College Mathematics STEM tasks.

Пример анализа LLM как самостоятельной модели

Выбрать задачи

☒ RWSD

☒ PARus

☒ RCB

☒ MultiQ

☒ ruWorldTree

☒ ruOpenBookQA

☒ CheGeKa

☒ ruTiE

☒ USE

☒ MathLogicQA

☒ ruMultiAr

☒ LCS

☒ ruModAr

☒ MaMuRAMu

☒ ruCodeEval

Выбрать домены

☒ Астрономия

☒ Безопасность

☒ Бизнес и управление

☒ Биология


☒ География

☒ Инженерия


☒ Искусство

Развернуть список доменов

RAG – пример сервиса, построенного вокруг модели



Критический навык – умение оценить, можно ли доверять сервису



Критический навык – умение оценить, можно ли доверять сервису



Greg Brockman ✓
@gdb



evals are surprisingly often all you need

6:24 PM · Dec 9, 2023 · **343.8K** Views



67



121



1.2K



136




Ручная проверка: дорого, но иногда нет выбора

LLM input	LLM output	Label	Comment
		✓	
		✓	
		✗	Irrelevant
		✗	Too wordy



Имея примеры правильных ответов, можно сравнить результаты с ними




Мы как разработчик/заказчик выставляем требование на желаемые характеристики сервиса


Response	Concise?	Polite?	Helpful?
	✓	✓	✓
	✓	✓	✗
	✓	✓	✗
	✓	✓	✓



В наиболее критических узлах системы мы ставим т.н. ограждения (guardrails)



В наиболее критических узлах системы мы ставим т.н. ограждения (guardrails)



Совместно с людьми «в полях», выполняющими процессы, мы выставляем набор тестов на работу сервиса

Q&A edge cases

Incomplete / empty

Input	Output

Time references

Input	Output

Foreign language

Input	Output

Business-specific

Competitor questions

Input	Output

Discontinued products

Input	Output

Discounts and offers

Input	Output

Sensitive topics

Financial advice

Input	Output

Medical advice

Input	Output

Legal advice


Input	Output



Содержание

- Так что же ты такое, агент?
- Как строить процессы вокруг агентов / агентов вокруг процессов?
- Оцениваем работу моделей: как полюбить черный ящик и начать жить
- **A2A**
- Вместо заключения

Agent to Agent (A2A)




Предприятия, потребители и целые отрасли будут представлены агентами ИИ, которые круглосуточно ведут переговоры, заключают контракты и совершают сделки от их имени.

Источник: [A2A by Google](#),

[Rise of the A2A economy: How AI agent to agent interactions will reshape the world](#)

Agent to Agent (A2A)




Предприятия, потребители и целые отрасли будут представлены агентами ИИ, которые круглосуточно ведут переговоры, заключают контракты и совершают сделки от их имени.

У потребителей появляются персональные ИИ агенты-ассистенты для различных аспектов жизни: финансов, развлечений, здравоохранения, путешествий, которые будут управлять повседневной жизнью в соответствии с личными предпочтениями, связями, ограничениями в питании, историей покупок и бюджетом.

Источник: [A2A by Google](#).

[Rise of the A2A economy: How AI agent to agent interactions will reshape the world](#)

Agent to Agent (A2A)



Предприятия, потребители и целые отрасли будут представлены агентами ИИ, которые круглосуточно ведут переговоры, заключают контракты и совершают сделки от их имени.

У потребителей появляются персональные ИИ агенты-ассистенты для различных аспектов жизни: финансов, развлечений, здравоохранения, путешествий, которые будут управлять повседневной жизнью в соответствии с личными предпочтениями, связями, ограничениями в питании, историей покупок и бюджетом.

Предприятия разворачивают команды специализированных ИИ-агентов, которые на экспертном уровне разбираются в ассортименте, товарных запасах, ценах, статусе доставки и даже юридических ограничениях.

Источник: [A2A by Google](#).

[Rise of the A2A economy: How AI agent to agent interactions will reshape the world](#)

Содержание

- Так что же ты такое, агент?
- Как строить процессы вокруг агентов / агентов вокруг процессов?
- Оцениваем работу моделей: как полюбить черный ящик и начать жить
- A2A
- **Вместо заключения**

Резюмируем

- Мир уже изменился; Модели, с которыми мы работаем сегодня – худшие из того, с чем мы столкнемся впредь

Резюмируем

- Мир уже изменился; Модели, с которыми мы работаем сегодня – худшие из того, с чем мы столкнемся впредь
- В зависимости от риска, сопряженного с агентом, его всегда можно использовать в качестве консультанта, а не актора

Резюмируем

- Мир уже изменился; Модели, с которыми мы работаем сегодня – худшие из того, с чем мы столкнемся впредь
- В зависимости от риска, сопряженного с агентом, его всегда можно использовать в качестве консультанта, а не актора
- Люди боятся автоматизации, однако это скорее возможность освободиться от рутины в пользу создания ценности

Резюмируем

- Мир уже изменился; Модели, с которыми мы работаем сегодня – худшие из того, с чем мы столкнемся впредь
- В зависимости от риска, сопряженного с агентом, его всегда можно использовать в качестве консультанта, а не актора
- Люди боятся автоматизации, однако это скорее возможность освободиться от рутины в пользу создания ценности
- Лучшие практики показывают, что идеи внедрения агентов приходят снизу, а не насаждаются сверху

Резюмируем

- Мир уже изменился; Модели, с которыми мы работаем сегодня – худшие из того, с чем мы столкнемся впредь
- В зависимости от риска, сопряженного с агентом, его всегда можно использовать в качестве консультанта, а не актора
- Люди боятся автоматизации, однако это скорее возможность освободиться от рутины в пользу создания ценности
- Лучшие практики показывают, что идеи внедрения агентов приходят снизу, а не насаждаются сверху
- Крайне важно правильно сформулировать внутри своей команды критерии успеха и неуспеха модели заранее

Резюмируем

- Мир уже изменился; Модели, с которыми мы работаем сегодня – худшие из того, с чем мы столкнемся впредь
- В зависимости от риска, сопряженного с агентом, его всегда можно использовать в качестве консультанта, а не актора
- Люди боятся автоматизации, однако это скорее возможность освободиться от рутины в пользу создания ценности
- Лучшие практики показывают, что идеи внедрения агентов приходят снизу, а не насаждаются сверху
- Крайне важно правильно сформулировать внутри своей команды критерии успеха и неуспеха модели заранее

СПАСИБО ЗА ВНИМАНИЕ