

Retrieval Augmented Generation (RAG)

Мурат Хажгериев

RAG закрывает важные проблемы классических моделей

- Решение проблемы knowledge cutoff

RAG закрывает важные проблемы классических моделей

- Решение проблемы knowledge cutoff
- Использование внутренних документов компании, которые модель наверняка не видела при обучении (полезно даже в случае on prem решений)

RAG закрывает важные проблемы классических моделей

- Решение проблемы knowledge cutoff
- Использование внутренних документов компании, которые модель наверняка не видела при обучении (полезно даже в случае on prem решений)
- Борьба с галлюцинациями (с возможностью давать ссылки на документы, использованные при ответе)



RAG закрывает важные проблемы классических моделей

- Решение проблемы knowledge cutoff
- Использование внутренних документов компании, которые модель наверняка не видела при обучении (полезно даже в случае on prem решений)
- Борьба с галлюцинациями (с возможностью давать ссылки на документы, использованные при ответе)
- Решение проблемы ограниченного контекста внимания



Вектора (эмбеддинги) ведут себя так, как мы бы ожидали

semantic: $v(\text{king}) - v(\text{man}) + v(\text{woman}) \approx v(\text{queen})$


syntactic: $v(\text{kings}) - v(\text{king}) + v(\text{queen}) \approx v(\text{queens})$




Вектора (эмбеддинги) ведут себя так, как мы бы ожидали

1-hot representation	Word embedding
	
• Noted o_w • Naive approach, no similarity information	• Noted e_w • Takes into account words similarity


Обзор поиска ближайших соседей (K-Nearest Neighbors)




Hierarchical Navigable Small World (HNSW)




Векторные базы данных хранят эмбединги объектов



Эмбединги генерируются, например, Encoder частью трансформера (BERT)




Мы также можем фильтровать объекты в базе данных по тегам




Возможности отдельной модели сильно ограничены обучающими данными и архитектурой

Вопрос клиента: «Каковы условия
досрочного погашения
потребительского кредита?»




Возможности отдельной модели сильно ограничены обучающими данными и архитектурой

Вопрос клиента: «Каковы условия досрочного погашения потребительского кредита?»




Ответ модели: «Обычно досрочное погашение кредита возможно, но может сопровождаться комиссией или ограничениями. Уточните детали в вашем банке.»


Добавление внешней базы данных позволяет качественно поменять характер модели





Добавление внешней базы данных позволяет качественно поменять характер модели



Retrieval-Augmented Generation Pipeline




RAG Pipeline: Retriever




RAG Pipeline: Retriever

Retrieval




RAG Pipeline: Generator


Generator



RAG Pipeline: собираем вместе



На практике релевантные куски данных часто еще раз реранжируются



Мы также можем использовать графовые базы данных для обогащения знания


user prompt: ... → 
context: 2 ↑




Elizabeth I $\xrightarrow{\text{siblings}}$ Mary
Elizabeth I $\xrightarrow{\text{title}}$ Queen

[Mary - sibling of El. I]
who would be title
of Queen.


Устройство Graph RAG



Мы можем объединять информацию из разных типов баз данных вместе



Энкодер генерирует контекстно-зависимые вектора для каждого входного токена




$(1,0,0), (0,1,0), (0,0,1)$




Кот, в, квартире

Энкодер генерирует контекстно-зависимые вектора для каждого входного токена




Мы можем получить вектор входной последовательности, например, агрегировав вектора-выходы энкодера



Term Frequency-Inverse Document Frequency (TF-IDF)

$$\text{tfidf}(t, d, D) = \text{tf}(t, d) \cdot \text{idf}(t, D)$$



Term Frequency-Inverse Document Frequency (TF-IDF)

$$\text{tfidf}(t, d, D) = \text{tf}(t, d) \cdot \text{idf}(t, D)$$

$$\text{tf}(t, d) = \frac{\sum_{t \in d} t}{|d|}$$

Term Frequency-Inverse Document Frequency (TF-IDF)


$$\text{tfidf}(t, d, D) = \text{tf}(t, d) \cdot \text{idf}(t, D)$$

$$\text{tf}(t, d) = \frac{\sum_{t \in d} t}{|d|}$$

$$\text{idf}(t, D) = 1 + \log\left(\frac{1 + |D|}{1 + \sum_{t \in D} t}\right)$$

BM25 (best matching 25)

$$\text{score}(D, Q) = \sum_{i=1}^n \text{IDF}(q_i) \cdot \frac{\overbrace{f(q_i, D)}^{df} \cdot (k_1 + 1)}{f(q_i, D) + k_1 \cdot \left(1 - b + b \cdot \frac{|D|}{\text{avgdl}}\right)}$$



$$\text{IDF}(q_i) = \ln \left(\frac{N - n(q_i) + 0.5}{n(q_i) + 0.5} + 1 \right)$$

BM25 (best matching 25)


$$\text{score}(D, Q) = \sum_{i=1}^n \text{IDF}(q_i) \cdot \frac{f(q_i, D) \cdot (k_1 + 1)}{f(q_i, D) + k_1 \cdot \left(1 - b + b \cdot \frac{|D|}{\text{avgdl}}\right)}$$

$$\text{IDF}(q_i) = \ln \left(\frac{N - n(q_i) + 0.5}{n(q_i) + 0.5} + 1 \right)$$


Hybrid search

- Reciprocal Rank Fusion: $\text{RRF_Score}(d) = \sum_{r \in \text{Ranks}} \frac{1}{k + \text{rank}_r}$

Sort documents by score




Assign rank positions



Apply the RRF formula

$$RRF_Score(d) = \sum_{r \in Ranks} \frac{1}{k + rank_r}$$




Add rank contributions, Return the top results

Document Number	Sum Calculation	Rank Score
Doc 1	$1/61 + 1/64 + 1/61$	0.0484
Doc 10	$1/62 + 1/61$	0.0325
Doc 11	$1/62$	0.0161
Doc 13	$1/62$	0.0161
Doc 20	$1/63$	0.0159
Doc 2	$1/63$	0.0159
Doc 25	$1/63$	0.0159
Doc 12	$1/64$	0.0156
Doc 14	$1/64$	0.0156

Hybrid search

- Reciprocal Rank Fusion: $RRF_Score(d) = \sum_{r \in Ranks} \frac{1}{k + rank_r}$
- LLM-based reranking: (см. доску)



Спасибо за внимание!