

NLP-2: Retrieval Augmented Generation (RAG)

Мурат Хажгериев


Содержание

- Ресар
- Плотные (Dense) vs. Разреженные (Sparse) эмбединги
- Строим RAG пайплайн
- Как я могу этому доверять?

Содержание


- **Ресар**
- Плотные (Dense) vs. Разреженные (Sparse) эмбединги
- Строим RAG пайплайн
- Как я могу этому доверять?

Возможности отдельной модели сильно ограничены обучающими данными и архитектурой




Возможности отдельной модели сильно ограничены обучающими данными и архитектурой

Вопрос клиента: «Каковы условия досрочного погашения потребительского кредита?»



Ответ модели: «Обычно досрочное погашение кредита возможно, но может сопровождаться комиссией или ограничениями. Уточните детали в вашем банке.»


Добавление внешней базы данных позволяет качественно поменять характер модели




Добавление внешней базы данных позволяет качественно поменять характер модели

Вопрос клиента: «Каковы условия досрочного погашения потребительского кредита?»

Контекст: *найденные релевантные факты из базы данных*




Данные из векторной базы (найденны в PDF с тарифами банка):
"Досрочное погашение возможно после 6 месяцев выплат. Комиссия – 1% от суммы погашения. Требуется письменное уведомление за 3 рабочих дня."





Ответ модели: «Согласно условиям нашего банка, досрочное погашение потребительского кредита разрешено после 6 месяцев выплат. При этом взимается комиссия 1% от суммы погашения, и необходимо уведомить банк письменно за 3 рабочих дня.»

Retrieval-Augmented Generation Pipeline




RAG Pipeline: Retriever




RAG Pipeline: Retriever

Retrieval




RAG Pipeline: Generator


Generator




RAG Pipeline: собираем вместе



На практике релевантные куски данных часто еще раз реранжируются



Векторные базы данных хранят эмбединги объектов




Huge text corpus




0.2	-1.7	...	2.3
0.4	0.5	...	-1.7
4.1	-1.9	...	-1.5
-1.1	0.7	...	5.3
-3.5	2.3	...	0.5
-1.7	0.4	...	0.2
2.3	0.2	...	0.7
-1.9	4.1	...	-2.4
0.5	-1.5	...	2.3

Embeddings

Эмбединги генерируются, например, Encoder частью трансформера (BERT)




Мы также можем фильтровать объекты в базе данных по тегам




Мы также можем использовать графовые базы данных для обогащения знания



Устройство Graph RAG




Мы можем объединять информацию из разных типов баз данных вместе




Содержание

- Ресар
- **Плотные (Dense) vs. Разреженные (Sparse) эмбединги**
- Строим RAG пайплайн
- Как я могу этому доверять?


Энкодер генерирует контекстно-зависимые вектора для каждого входного токена




Мы можем получить вектор входной последовательности, например, агрегировав вектора-выходы энкодера




Эта модель может быть использована как генератор эмбеддингов. Пример – Bi-Encoder.




Эта модель может быть использована как генератор эмбеддингов. Пример – Bi-Encoder.



Другой подход - обрабатывать вход парами (Cross-Encoder)



Обучаем с помощью Contrastive Loss



InfoNCE / Multiple Negatives Ranking Loss

↑


↗

$$\mathcal{L}_{\text{InfoNCE}} = -\log \frac{\exp(\text{sim}(q, d^+)/\tau)}{\exp(\text{sim}(q, d^+)/\tau) + \sum_{i=1}^K \exp(\text{sim}(q, d_i^-)/\tau)}$$

Batch: $\left[\begin{array}{l} \text{query}_0 : doc_0 \\ q_3 : doc_1 \\ q_1 : doc_2 \\ \vdots \\ q_2 : doc_3 \end{array} \right.$

$\overset{+}{\longleftrightarrow}$
 $q_0 : doc_0$
 $q_0 : doc_{1:5}$
 $\longleftarrow$

Современные архитектуры для задачи similarity search обучаются в парадигме Matryoshka




Источник: <https://huggingface.co/blog/matryoshka>

Функция потерь составная с участием эмбеддингов

$$\underline{\mathcal{L}_{\text{MRL}}} = \sum_{m \in \mathcal{M}} \underset{\text{!}}{c_m} \cdot \mathcal{L}_{\text{base}}(\underline{z_{1:m}}, y)$$

Term Frequency-Inverse Document Frequency (TF-IDF)


$$doc = \begin{cases} ind: [452, 1043 \dots] \\ val: [0.4, 0.3, 0.1 \dots] \end{cases} \quad tfidf(t, d, D) = tf(t, d) \cdot idf(t, D)$$



Term Frequency-Inverse Document Frequency (TF-IDF)

$$\text{tfidf}(t, d, D) = \text{tf}(\underline{t}, d) \cdot \text{idf}(t, D)$$

$$\text{tf}(t, d) = \frac{\sum_{t \in d} t}{|d|}$$



Term Frequency-Inverse Document Frequency (TF-IDF)

$$\text{tfidf}(t, d, D) = \text{tf}(t, d) \cdot \text{idf}(t, D)$$

$$\text{tf}(t, d) = \frac{\sum_{t \in d} t}{|d|}$$

$$\text{idf}(t, D) = 1 + \log\left(\frac{1 + |D|}{1 + \sum_{t \in D} t}\right)$$

BM25 (best matching 25)

$$\text{score}(D, Q) = \sum_{i=1}^n \text{IDF}(q_i) \cdot \frac{f(q_i, D) \cdot (k_1 + 1)}{f(q_i, D) + k_1 \cdot \left(1 - b + b \cdot \frac{|D|}{\text{avgdl}}\right)}$$

$Q = [0 \ 0 \ 1 \ 0 \ 1 \ 1 \dots]$
|
141

$$\text{IDF}(q_i) = \ln \left(\frac{N - n(q_i) + 0.5}{n(q_i) + 0.5} + 1 \right)$$

BM25 (best matching 25)


$$\text{score}(D, Q) = \sum_{i=1}^n \text{IDF}(q_i) \cdot \frac{f(q_i, D) \cdot (k_1 + 1)}{f(q_i, D) + k_1 \cdot \left(1 - b + b \cdot \frac{|D|}{\text{avgdl}}\right)}$$

$$\text{IDF}(q_i) = \ln \left(\frac{N - n(q_i) + 0.5}{n(q_i) + 0.5} + 1 \right)$$

Содержание

- Ресар
- Плотные (Dense) vs. Разреженные (Sparse) эмбединги
- **Строим RAG пайплайн**
- Как я могу этому доверять?


Пример эффективного RAG пайплайна (зависит от вашего домена)




Hybrid search

- Reciprocal Rank Fusion: $RRF_Score(d) = \sum_{r \in Ranks} \frac{1}{k + rank_r}$

Sort documents by score




Assign rank positions



Apply the RRF formula

$$\underline{RRF_Score(d)} = \sum_{r \in Ranks} \frac{1}{k + rank_r}$$



Add rank contributions, Return the top results



Document Number	Sum Calculation	Rank Score
Doc 1	$1/61 + 1/64 + 1/61$	0.0484
Doc 10	$1/62 + 1/61$	0.0325
Doc 11	$1/62$	0.0161
Doc 13	$1/62$	0.0161
Doc 20	$1/63$	0.0159
Doc 2	$1/63$	0.0159
Doc 25	$1/63$	0.0159
Doc 12	$1/64$	0.0156
Doc 14	$1/64$	0.0156

Hybrid search

- Reciprocal Rank Fusion: $RRF_Score(d) = \sum_{r \in Ranks} \frac{1}{k + rank_r}$
- Cross-Encoder

 $\rightarrow \text{softmax}(\cdot)$

Пример эффективного RAG пайплайна (зависит от вашего домена)

Этап 0: retrieval

Sparse: Ключевые слова/BM25/BGE

Dense: Матрешка (малая размерность)



Этап 1: retrieval

Dense: Матрешка (большая размерность)



Этап 2: Reranking

Cross-Encoder

$$\mathbb{P} \left[\begin{array}{l} q, doc-0 = \langle cls \rangle q \langle sep doc eos \rangle \\ q, doc-1 \end{array} \right]$$

Содержание

- Ресар
- Плотные (Dense) vs. Разреженные (Sparse) эмбединги
- Строим RAG пайплайн
- **Как я могу этому доверять?**

Как померить качество?

		Actual Values	
		Positive (1)	Negative (0)
Predicted Values	Positive (1)	TP	FP
	Negative (0)	FN	TN

$$Precision = \frac{TP}{TP + FP}$$

$$Recall = \frac{TP}{TP + FN}$$

Precision, Recall

$$\text{Precision at } K = \frac{\text{Number of relevant items in } \underline{K}}{\text{Total number of items in } \underline{K}}$$

$$\text{Recall at } K = \frac{\text{Number of relevant items in } \underline{K}}{\text{Total number of relevant items}}$$

Mean Average Precision (MAP)

$$\begin{aligned} \text{Precision@2} &= \frac{1}{2} \\ \text{Precision@4} &= \frac{2}{4} = \frac{1}{2} \\ \text{Precision@6} &= \frac{3}{6} = \frac{1}{2} \end{aligned}$$

$$\left\{ \begin{array}{l} 0. \\ 1. + \\ \hline 2. \\ 3. + \\ \hline 4. \\ 5. + \\ \hline 6. \end{array} \right\}$$

$$\text{MAP@K} = \frac{1}{U} \sum_{u=1}^U \text{AP@K}_u$$

Mean Average Precision (MAP)

Rank	Item	Precision@k
1	Relevant	$1/1 = 1$
2	Not relevant	$1/2 = 0.5$
3	Not relevant	$1/3 = 0.33$
4	Relevant	$2/4 = 0.5$
5	Relevant	$3/5 = 0.6$
6	Not relevant	$3/6 = 0.5$

Average precision

$$AP@6 = \frac{1 + 0.5 + 0.6}{3} = 0.7$$

Not relevant Relevant

Mean Reciprocal Rank (MRR)

$$q_0 : \frac{1}{3}$$

$$q_1 : \frac{1}{5}$$

0.
1.
2.

3.
4. +

5. +
:
:


$$\text{MRR} = \frac{1}{U} \sum_{u=1}^U \frac{1}{\text{rank}_i}$$

Normalized Discounted Cumulative Gain (NDCG)

$$CG@K = \sum_{k=1}^K G_i = 0.5 + 0.5 + 1$$

winner
↓
q₀: 0. 0.5
1. ~~1~~ 1.03
2. 0.5 2.05
3. 3.
4. 0.5 4. 1

Normalized Discounted Cumulative Gain (NDCG)




Normalized Discounted Cumulative Gain (NDCG)

$$\text{DCG}@K = \sum_{k=1}^K \frac{\overset{\text{↙}}{rel_i}}{\log_2(i + 1)}$$

Normalized Discounted Cumulative Gain (NDCG)

K = 3


$$\text{DCG}@3 = \frac{1}{\log_2(1 + 1)} + \frac{0}{\log_2(1 + 2)} + \frac{1}{\log_2(1 + 3)}$$
$$\text{DCG}@3 = 1 + 0 + 0.5 = 1.5$$




Normalized Discounted Cumulative Gain (NDCG)

$$\begin{aligned}k = 1: & \frac{1}{\log_2(1+1)} = \frac{1}{\log_2(2)} = \frac{1}{1} = 1 \\k = 2: & \frac{1}{\log_2(1+2)} = \frac{1}{\log_2(3)} \approx \frac{1}{1.585} \approx 0.63 \\k = 3: & \frac{1}{\log_2(1+3)} = \frac{1}{\log_2(4)} = \frac{1}{2} = 0.5 \\k = 4: & \frac{1}{\log_2(1+4)} \approx \frac{1}{\log_2(5)} \approx \frac{1}{2.322} \approx 0.43 \\k = 5: & \frac{1}{\log_2(1+5)} \approx \frac{1}{\log_2(6)} \approx \frac{1}{2.585} \approx 0.39\end{aligned}$$

Normalized Discounted Cumulative Gain (NDCG)

K = 3



$$DCG@3 = \frac{1}{\log_2(1+1)} + \frac{0}{\log_2(1+2)} + \frac{1}{\log_2(1+3)}$$

$$DCG@3 = 1 + 0 + 0.5 = 1.5$$

Normalized Discounted Cumulative Gain (NDCG)

$$\text{NDCG@K} = \frac{DCG@K}{\text{IDCG@K}}$$

Спасибо за внимание!

